TECH CHALLENGE - FASE 2

Predição de Aprovação de Pedidos De Cartão De Crédito

Grupo 33

RM377836	ANGELICA FONSECA DE FREITAS
RM377812	FERNANDA DE OLIVEIRA ALMEIDA
RM377814	GABRIELA SOUZA E SILVA
RM377805	JULIANA OLIVEIRA COUTO ESPINDOLA VAZ DE LIMA
RM377758	WILLIAM VLADIMIR ROSALES MERIDA DA SILVA



Prever quem tende a pagar e quem tende a atrasar

Transformar dados cadastrais e de pagamento em informação útil para a análise de crédito.

01

Objetivo

Desenvolver um modelo de aprendizado de máquina (Machine Learning) capaz de prever, na hora da concessão, se um solicitante tem perfil de “bom” ou “mau pagador”.

02

Mitigação de riscos

Apoiar a análise de crédito para reduzir perdas financeiras por inadimplência.



Só 8% dos solicitantes têm histórico de pagamento

Da base bruta ao conjunto de modelagem.

01
CADASTRO
438 mil solicitantes, após a limpeza

02
HISTÓRICO
1 milhão de registros mensais de 46 mil clientes

03
PREPARAÇÃO
Limpeza e junção das bases

04
ALVO
Definição do que prever, por cliente

05
MODELO
Treino e validação

8,3%

dos solicitantes aparecem nas duas bases: 36.457 de 438.463 clientes. Só neles sabemos quem pagou e quem atrasou; os outros 402 mil ficam de fora.

REGRA DE OURO

Definir o que é inadimplência antes de treinar o modelo: ele aprende a prever exatamente essa definição.

Dois critérios de mau pagador: 90 e 30 dias

Cada cliente é marcado se, em algum mês do histórico, teve atraso dentro da regra.

PRINCIPAL

Inad90 · Mau pagador · Rígido

Regra: Atraso de 90 dias ou mais (status 3, 4 ou 5).

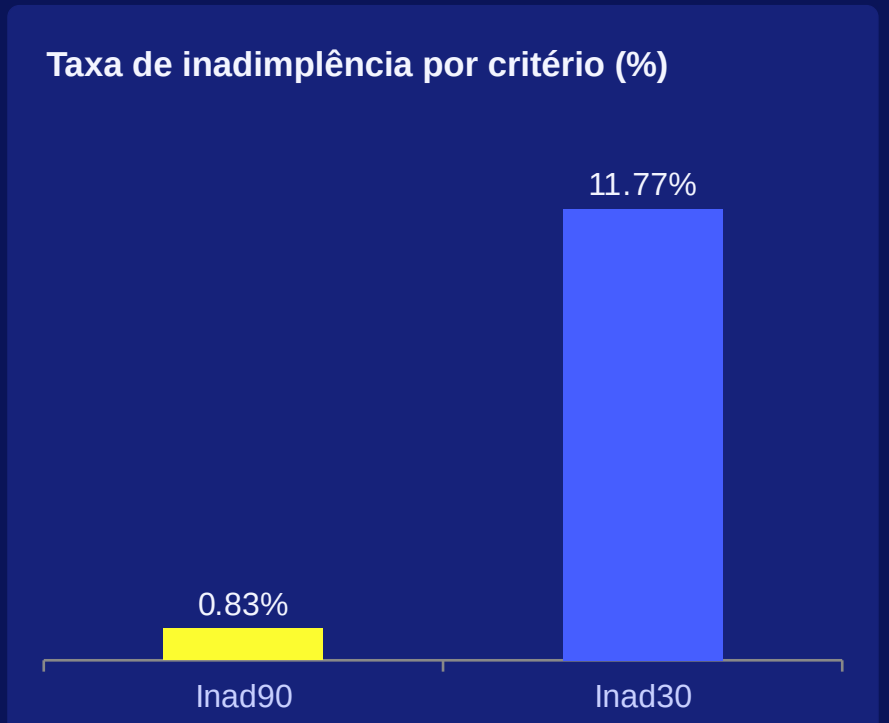
Resultado: É o prejuízo real. São 302 clientes (0,83%).

ALTERNATIVO

Inad30 · Critério permissivo

Regra: Atraso de 30 dias ou mais (status 1 a 5).

Resultado: Captura sinais precoces. São 4.291 clientes (11,8%).



Atrasos de até 29 dias (status 0) não contam: aparecem em 36% dos meses. Os 3.989 clientes com atrasos de 30 a 89 dias ficam na base: são bons pagadores no critério de 90 dias.

Preparamos os dados para o modelo aprender bem

O modelo só enxerga o que se sabe no dia em que o cliente pede o cartão.

01

Limpeza do cadastro

Removemos 94 registros de códigos repetidos, tratamos os 31% sem ocupação como grupo próprio e criamos idade, anos de trabalho e o indicador de aposentado.

02

17 variáveis do pedido

O tamanho do histórico ficou de fora: só existe depois da aprovação e distorce, pois a taxa de atraso sobe de 0,15% para 2,33% só com o tempo de observação.

03

Ajustes só com o passado

Valores extremos limitados, renda em escala logarítmica e categorias raras agrupadas, tudo calculado só com o estudo, nunca com a prova.

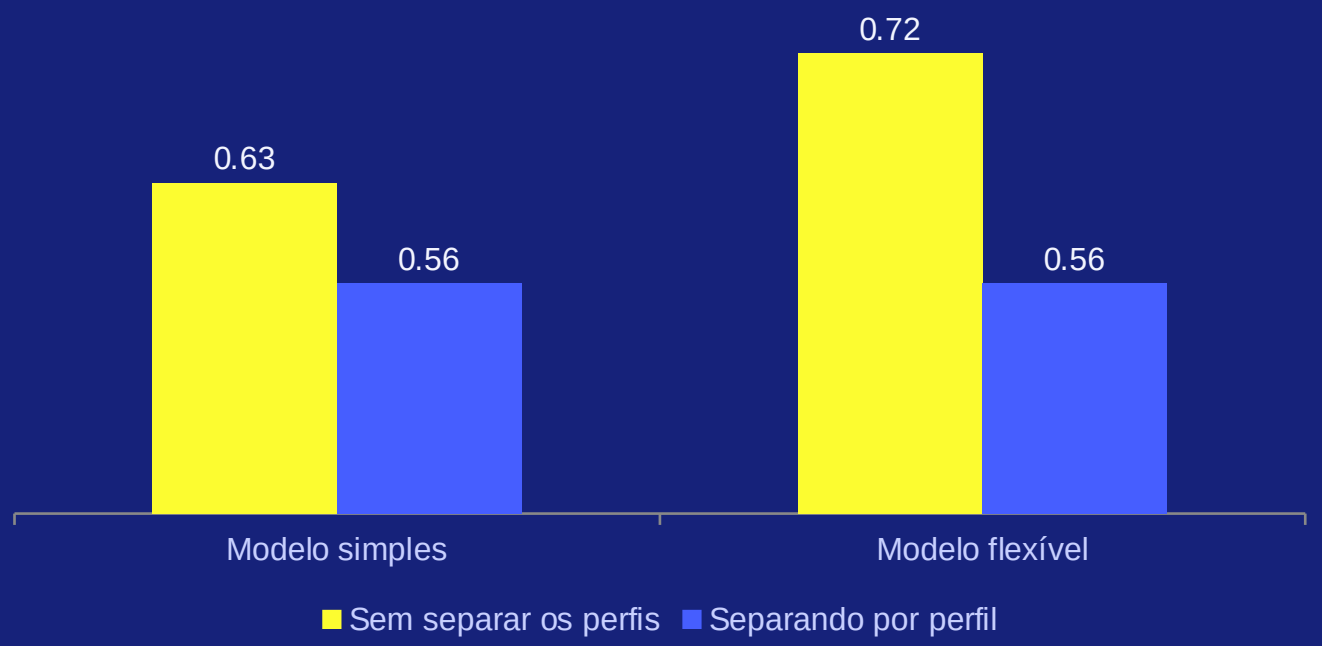
ACURÁCIA ISOLADA NÃO BASTA

Um modelo que sempre responde “bom pagador” acertaria mais de 99% dos clientes pelo critério principal, sem identificar nenhum caso de risco.

Sem separar perfis repetidos, o resultado engana

Cerca de 96% dos clientes têm um “gêmeo”: outro cliente com todas as informações idênticas.

Capacidade de ordenar o risco (atraso grave): quanto maior, melhor; 0,5 = sorteio



O RISCO

Se um gêmeo fica no estudo e o outro na prova, o modelo decora o perfil e o resultado parece ótimo.

O QUE FIZEMOS

Separamos estudo e prova por perfil: o mesmo perfil nunca está dos dois lados. O resultado em azul é o que vale para clientes novos.

Dois modelos e métricas que olham os casos raros

Ambos ajustados para dar mais peso aos maus pagadores, que são raros.

REFERÊNCIA

Sem perfil

Sempre devolve a taxa média de inadimplência. É o piso: qualquer modelo útil precisa superá-lo.

MODELO SIMPLES

Fácil de explicar

Cada característica do cliente ganha um peso que aumenta ou diminui o risco.

MODELO FLEXÍVEL

Mais sofisticado

Combina muitas regras de decisão e capta relações mais complexas, ao custo de ser mais difícil de explicar.

RECALL

Encontra os maus pagadores?

PRECISÃO

Os alertas estão certos?

F1-SCORE

Há equilíbrio entre os dois?

ROC-AUC

Ordena bem o risco?

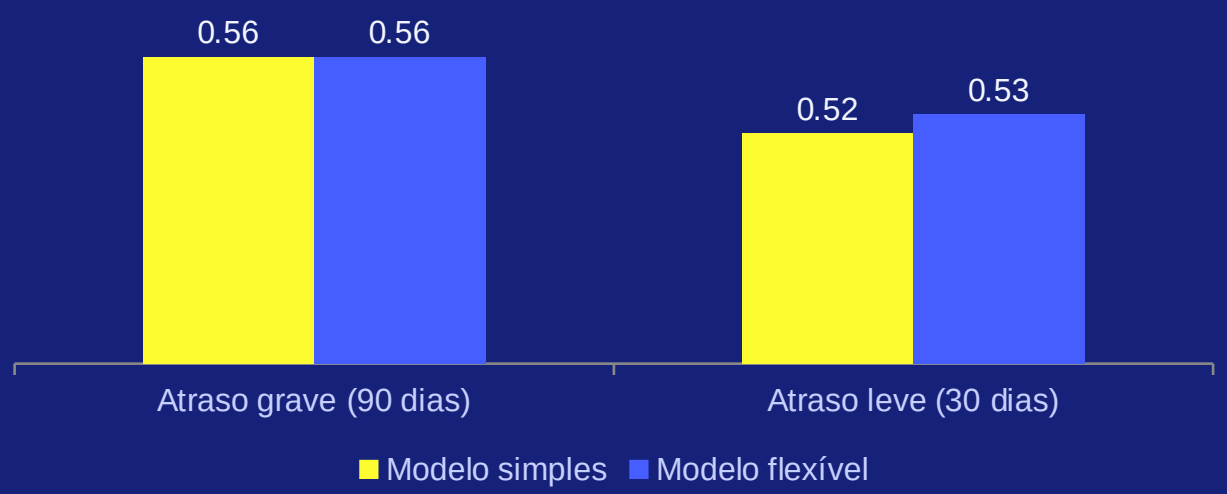
O acerto geral não entra: com tão poucos maus pagadores, ele esconde o que importa.

07 · RESULTADO DA VALIDAÇÃO

O cadastro sozinho prevê pouco

Resultado honesto, com perfis separados: a limitação está na informação, não no algoritmo.

Capacidade de ordenar o risco: quanto maior, melhor; 0,5 = sorteio



ATRASO GRAVE

Ordena só um pouco melhor que um sorteio e encontra algumas vezes mais casos do que o acaso, ainda em patamar baixo.

ATRASO LEVE

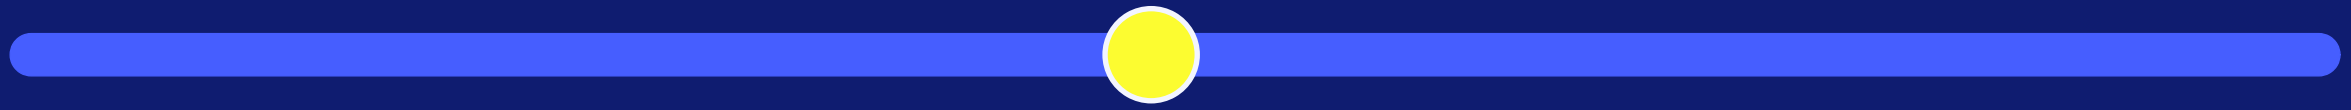
Praticamente um sorteio. Os dois modelos empatam.

TESTE FINAL (NOTEBOOK 4)

[preencher com o resultado no teste: capacidade de ordenar o risco e casos encontrados]

O ponto de corte muda o tipo de erro

A probabilidade prevista vira um alerta quando passa de um ponto de corte.



Mais alertas

Menos alertas

Ponto de corte mais baixo

Sinaliza mais casos: encontra mais maus pagadores, mas gera também mais alarmes falsos.

Ponto de corte mais alto

Sinaliza menos casos: reduz os alarmes falsos, mas deixa mais risco passar.

NO CORTE PADRÃO (0,5)

O modelo simples encontra 43 em cada 100 inadimplentes graves, mas só 1 em cada 100 alertas está certo. A escolha do corte depende do custo de cada erro e será definida na avaliação final.

09 · CONCLUSÃO

Alvo claro, validação honesta e sinal fraco

O modelo serve como apoio à triagem na decisão de crédito, e não como decisor único.

ALVO CLARO

Mau pagador é quem atrasa 90 dias ou mais (302 clientes, 0,83%); 30 dias é o critério alternativo (4.291 clientes, 11,8%).

VALIDAÇÃO HONESTA

Estudo e prova separados por perfil e resultados apresentados em faixas, não em um número único.

SINAL FRACO

O cadastro sozinho ordena o risco só um pouco melhor que um sorteio no atraso grave, e quase nada no atraso leve.

LIMITES E PRÓXIMO PASSO

Aprendemos só com 8% dos solicitantes, e o teste tem poucos casos graves (por isso, faixas). Próximo passo: a avaliação final no teste e a escolha do ponto de corte.