TECH CHALLENGE - FASE 2

Predição de Aprovação de Pedidos De Cartão De Crédito



Grupo 33

RM377836	ANGELICA FONSECA DE FREITAS
RM377812	FERNANDA DE OLIVEIRA ALMEIDA
RM377814	GABRIELA SOUZA E SILVA
RM377805	JULIANA OLIVEIRA COUTO ESPINDOLA VAZ DE LIMA
RM377758	WILLIAM VLADIMIR ROSALES MERIDA DA SILVA

Prever quem tende a pagar e quem tende a atrasar

Transformar dados cadastrais e de pagamento em informação útil para a análise de crédito.

01

Objetivo

Desenvolver um modelo de aprendizado de máquina (Machine Learning) capaz de prever, na hora da concessão, se um solicitante tem perfil de “bom” ou “mau pagador”.

02

Mitigação de riscos

Ordenar os solicitantes por risco e apoiar a triagem, para o analista concentrar a atenção onde mais importa e reduzir perdas por inadimplência.



Só 8% dos solicitantes têm histórico de pagamento

Análise exploratória descritiva: da base bruta ao conjunto de modelagem.

01
CADASTRO
438 mil solicitantes, após a limpeza

02
HISTÓRICO
1 milhão de registros mensais de 46 mil clientes

03
PREPARAÇÃO
Limpeza e junção das bases

04
ALVO
Definição do que prever, por cliente

05
MODELO
Treino e validação

8,3%

dos solicitantes aparecem nas duas bases: 36.457 de 438.463 clientes.

REGRA DE OURO

Definir o que é inadimplência antes de treinar o modelo: ele aprende a prever exatamente essa definição.

Dois critérios de mau pagador: 90 e 30 dias

Cada cliente é marcado se, em algum mês do histórico, teve atraso dentro da regra.

PRINCIPAL

Inad90 · Mau pagador · Rígido

Regra: Atraso de 90 dias ou mais (status 3, 4 ou 5).

Resultado: É o prejuízo real e a convenção de mercado. São 302 clientes (0,83%).

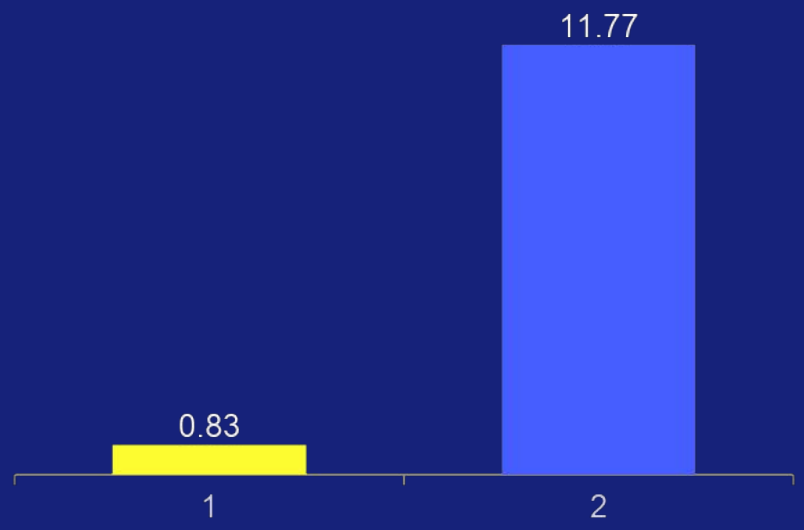
ALTERNATIVO

Inad30 · Critério permissivo

Regra: Atraso de 30 dias ou mais (status 1 a 5).

Resultado: Captura sinais precoces. São 4.291 clientes (11,8%).

Taxa de inadimplência por critério (%)



Atrasos de até 29 dias (status 0) não contam: aparecem em 36% dos meses. Os 3.989 clientes com atrasos de 30 a 89 dias ficam na base: são bons pagadores no critério de 90 dias.

04 · PREPARAÇÃO

Preparamos os dados para o modelo aprender bem

01

Limpeza do cadastro

Removemos 94 registros de códigos repetidos, tratamos os 31% sem ocupação como grupo próprio e criamos idade, anos de trabalho e o indicador de aposentado.

02

17 variáveis do pedido

O tamanho do histórico ficou de fora: só existe depois da aprovação e distorce, pois a taxa de atraso sobe de 0,15% para 2,33% só com o tempo de observação.

03

Ajustes só com o passado

Valores extremos limitados, renda em escala logarítmica e categorias raras agrupadas, tudo calculado só com o estudo, nunca com a prova.

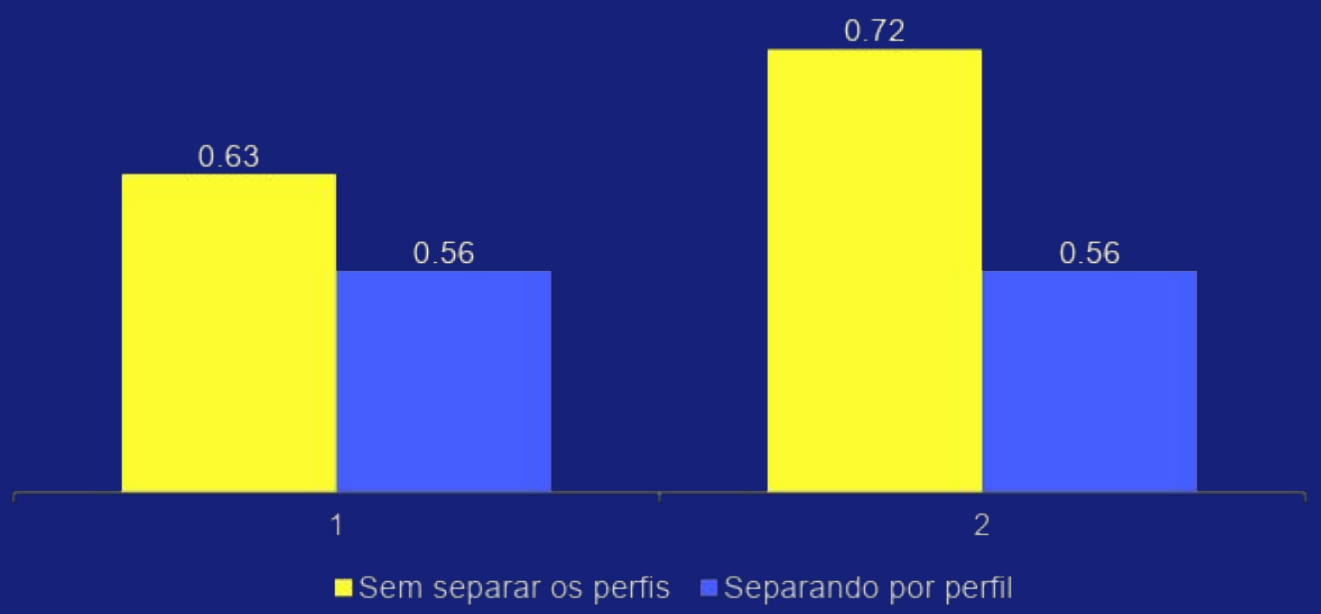
ACURÁCIA ISOLADA NÃO BASTA

Um modelo que sempre responde “bom pagador” acertaria mais de 99% dos clientes pelo critério principal, sem identificar nenhum caso de risco.

Sem separar perfis repetidos, o resultado engana

Cerca de 96% dos clientes têm um “**gêmeo**”: outro cliente com todas as informações idênticas.

Capacidade de ordenar o risco (atraso grave): quanto maior, melhor; 0,5 = sorteio



O RISCO

Se um gêmeo fica no estudo e o outro na prova, o modelo decora o perfil e o resultado parece ótimo.

O QUE FIZEMOS

Separamos estudo e prova por perfil: o mesmo perfil nunca está dos dois lados. O resultado em azul é o que vale para clientes novos.

Dois modelos e métricas que olham os casos raros

Ambos ajustados para dar mais peso aos maus pagadores, que são raros.

REFERÊNCIA

Sem perfil

Sempre devolve a taxa média de inadimplência. É o piso: qualquer modelo útil precisa superá-lo.

MODELO SIMPLES (Regressão Logística)

Fácil de explicar

Cada característica do cliente ganha um peso que aumenta ou diminui o risco.

MODELO FLEXÍVEL (Random Forest)

Mais sofisticado

Combina muitas regras de decisão e capta relações mais complexas, ao custo de ser mais difícil de explicar.

RECALL
Encontra os maus pagadores?

PRECISÃO
Os alertas estão certos?

F1-SCORE
Há equilíbrio entre os dois?

ROC-AUC
Ordena bem o risco?

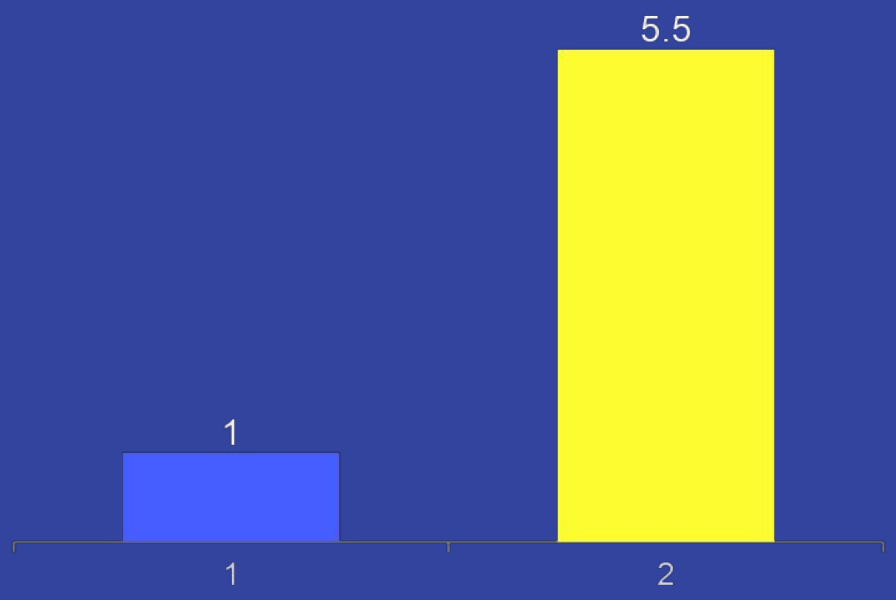
AUC-PR
Acerta nos casos raros?

O acerto geral não entra: com tão poucos maus pagadores, ele esconde o que importa. A AUC-PR é a métrica principal.

No teste, o valor do modelo está no topo do ranking

Atraso grave: o modelo supera o sorteio e concentra a inadimplência nos pedidos de maior risco.

Inadimplência grave entre os pedidos (%)



NO TESTE, COM CLIENTES NOVOS

Atraso grave: o modelo ordena o risco melhor que um sorteio (0,60), com sinal modesto. Atraso leve: quase nada (0,55). Os dois modelos empatam; levamos o simples e explicável. Pesam mais o tempo de trabalho e a idade.

PONTO DE CORTE

Escolhido no estudo, não no teste. No corte padrão (0,5), o modelo encontra cerca de 4 em cada 10 inadimplentes graves, mas só 1 em cada 100 alertas acerta. Por isso olhamos o topo: a cada 1.000 pedidos, sinalizar 5% é apontar 36 clientes, e só 2 são inadimplentes.

O QUE FAZER COM ISSO

Sinalizar para análise adicional, e não recusar automaticamente.

08 · CONCLUSÃO

Prevê pouco, mas ajuda a priorizar quem analisar primeiro

O cadastro permite priorizar a análise do atraso grave, mas não decidir sozinho.

1 O QUE CONCLUÍMOS

É possível prever em parte. O modelo ordena o risco de atraso grave só um pouco melhor que um sorteio, mas o valor está no topo do ranking: os 5% de maior risco têm inadimplência de 5,5%, cerca de 5 vezes a média (1,0%).

2 O QUE ISSO SIGNIFICA PARA O NEGÓCIO

Serve para triagem: sinalizar os pedidos de maior risco para análise adicional. Recusar automaticamente só compensaria se o calote custasse de 50 a 100 vezes um bom cliente recusado. No atraso leve (30 dias), quase não há ganho.

3 POR QUE O SINAL É FRACO

Usamos só o que existe no pedido. O histórico de pagamento ficou de fora: um cliente novo não o tem, e o tempo de observação distorce o resultado (de 0,15% para 2,33%). Os dois modelos empatam: o limite está na informação, não no algoritmo.

4 LIMITAÇÕES

Aprendemos com os 8% de solicitantes que têm histórico, que podem não representar todos. Os maus pagadores são raros (302 casos), por isso mostramos faixas, e não um número único. Idade, estado civil e sexo exigem revisão jurídica.